

Clasificación de imágenes de fondo de ojo retinal en pacientes con retinopatía diabética.

A. Chamizo González¹, Y. Le Bars¹, A.Chraibi¹

¹ Grado en Ingeniería Biomédica, Universidad Rey Juan Carlos, Madrid, España.



Abstract

La diabetes tipo II es una de las enfermedades más prevalentes en el mundo. Asociada a la misma, aparece una patología: la retinopatía diabética, que puede llegar a causar ceguera graves incapacitantes.

La retinopatía diabética aparece como un daño a los vasos sanguíneos de los tejidos sensibles a la luz en la retina. Estos daños se pueden manifestar como exudados duros, exudados blandos, neovascularizaciones, puntos pequeños rojos y hemorragias pequeñas.

El objetivo de este proyecto es clasificar exudados duros en imágenes de fondo de ojo retinal mediante el uso de una red neuronal convolucional (CNN). Proponemos un método de segmentación para comparar la performance de una CNN cuando recibe las imágenes directamente desde la base de datos y cuando las recibe segmentadas.

1. Introducción

La diabetes mellitus es un grupo de desórdenes metabólicos que tienen como elemento común un elevado nivel de azúcar en sangre (hiperglicemia), siendo sus principales síntomas la poliuria, polidipsia y polifagia. La diabetes tipo II, que es su versión más conocida, está relacionada con un gran número de complicaciones a largo plazo, asociadas a una mayor morbilidad y riesgo de mayor tiempo de hospitalización en pacientes diabéticos [1].

Una de las patologías relacionadas con la diabetes tipo II es la retinopatía diabética. La retinopatía diabética es una condición relacionada que aparece como un daño en los tejidos sensibles a la luz en la retina, principalmente en los vasos sanguíneos. [2] Ese daño se manifiesta como exudados duros, exudados blandos, neovascularizaciones, puntos pequeños rojos y hemorragias pequeñas en las imágenes de fondo de ojo. Además, es una de las principales causas de ceguera en países desarrollados.

Dado que el análisis de estas imágenes requiere de mucho tiempo y experiencia, han aparecido muchos y diversos métodos para el análisis de los mismos, siendo los más modernos aquellos basados en entropía [3].

Se propone un método de segmentación de exudados duros y vasos sanguíneos, aunque puede ser extendido a exudados blandos, neovascularizaciones,... con el objetivo de comprobar si nuestras segmentaciones son mejores que aquellas que obtiene una red neuronal convolucional a partir del mapa de características.

Por razones de tiempo, este método se limita únicamente a comparar lo que ocurre con exudados duros; sin embargo, queda a expensas de futuras investigaciones la puesta en marcha para la clasificación del resto de defectos.

La distribución del trabajo se ha realizado de la siguiente manera:

- Software para la segmentación: Aitor.
- Software para la creación de la red neuronal convolucional: Aitor.
- Paper y póster explicativo del proyecto: Aitor.

2. Material y métodos

La base de datos empleada es DiaretDB0, versión 1. Esta base de datos se suele utilizar para realizar benchmarking con imágenes propias de hospitales dada su gran calidad y la presencia de ground truths con los que contrastar los resultados. Esta base de datos se puede encontrar como parte del proyecto de ImageRet [4].

Se ha creado un método para la segmentación de exudados duros (generalizable a otra clase de defectos) y otro para la segmentación de vasos sanguíneos.

La segmentación de vasos sanguíneos como paso intermedio a la hora de poder detectar de forma automática lesiones rojas, ya que en muchas ocasiones pueden ser confundidas entre sí (tanto los vasos sanguíneos como algunas lesiones rojas tienen valores de gris similares). Aunque no se ha empleado directamente en este proyecto, sí se puede emplear como parte de un proyecto a futuros. Para la segmentación de los mismos se ha seguido el siguiente proceso:

- División de la imagen en cada uno de los tres canales del espacio RGB, quedándonos con el canal G (verde). Este canal es muy importante dado que es en el que tanto los vasos sanguíneos como el resto de lesiones se perciben con mayor facilidad[5].
- Aplicación de filtrado por secuenciación alternante (ASF)[6]. Este método consiste en una serie de operaciones morfológica de apertura y cerrado con elementos estructurantes variantes. Se ha realizado un total de 3 veces: la primera vez se ha elegido un elemento estructurante de tamaño 5x5, la segunda vez de 11x11 y la tercera

vez de 23x23. En todos los casos, dicho elemento tenía forma de elipse.

- A la salida de dicho filtrado, obtenemos una imagen que es sustraída a la imagen del canal verde. Sobre esta imagen, aplicamos el algoritmo CLAHE como método de corrección de defectos de iluminación[3]. Este algoritmo toma pequeños parches de la imagen de forma iterativa en vez de la imagen completa, lo que lo convierte en una alternativa ideal a la ecualización del histograma. En este caso, es clave su uso dada la gran inhomogeneidad de iluminación de las imágenes de fondo de ojo.
- Posteriormente, se aplica una umbralización de la imagen para ser preparada para el marcado de contornos. Este marcado de contornos se realizará mediante el algoritmo snakes con el objetivo de segmentar la mayor cantidad posible de vasos sanguíneos y obtenerlos en una imagen distinta a la original.

Por otro lado, también se ha generado un algoritmo para la detección de *notches*. Definimos *notch* como aquel defecto en la imagen que está asociado a un exudado principalmente. Por otro lado, definimos *blob* como aquella zona de la imagen en la que se detecta una inhomogeneidad en color o iluminación:

- En primer lugar, convertimos la imagen a escala de gris y la umbralizamos.
- A la salida de esta umbralización, calculamos un bounding box. Este bounding box se encontrará en aquella zona donde mayor probabilidad hay de encontrar un exudado en una imagen de fondo de ojo estándar; la idea es que todas las imágenes a analizar estén centradas en la misma posición y normalizadas. A la salida de este cálculo, se vuelve a umbralizar la imagen. [7]
- A continuación, procedemos con la detección del notch. En el caso de que se detectase, se procede con una rotación de la imagen. La idea es que los ojos izquierdos y derechos tengan la fovea en la misma localización (para mejorar la robustez en las predicciones por parte de la red neuronal).
- Para la detección de dicho notch, seguimos los siguientes pasos:
 - En primer lugar, se aplica una transformada de Hough para encontrar un círculo que se corresponda con el campo de visión. [3] Dado que se ha observado empíricamente que dicho campo tiene algunos defectos, previamente a dicha transformada se procede con la aplicación de una apertura de la imagen. La apertura de la imagen se ha realizado con un elemento estructurante con forma rectangular y de tamaño 3x3.

Se ha determinado de forma empírica que la mayoría de los exudados a clasificar se encuentran en una ROI determinada (a 45

grados en el cuadrante superior derecho). Una vez hemos obtenido esta zona, procedemos a detectar los posibles *blobs* mediante *selective search*. Para ello, se han tenido en cuenta parámetros como la textura, el color, la forma o el área de los mismos.

- Finalmente, aplicamos el algoritmo CLAHE para tratar las posibles inhomogeneidades restantes de iluminación. [3]

Una vez diseñados los algoritmos de segmentación, se procedió con el diseño de la red neuronal convolucional. Para ello, se ha implementado el siguiente diseño:

- ResNet50. Esta red se ha implementado con 50 capas y sin tener en cuenta los pesos de ImageNet. Por tanto, no se ha tenido en cuenta en este trabajo el posible efecto (y mejora) que pudiera haber tenido con el *transfer learning*.
- Capa densa con 2048 nodos.
- Capa densa con 1024 nodos.
- Capa densa con 256 nodos.
- Capa densa final, utilizando la función de activación Softmax.

El número de parámetros totales que se han empleado han sido de 30.144.897.

A continuación, mostramos una figura con la arquitectura de la red empleada:




Figura 1. Red neuronal convolucional basada en ResNet50.

3. Resultados

Se ha obtenido una precisión de 0.73 para las imágenes sin segmentar. A continuación, mostramos las figuras de mérito de accuracy y función de pérdida correspondientes.




Figura 2. Accuracy y función de pérdida en algunas épocas de la red convolucional sobre imágenes sin segmentar.

En lo que se refiere a nuestro algoritmo, no ha ofrecido resultados superiores a los que se ofrece con la red, contradiciendo la hipótesis inicial.

4. Discusión y conclusiones.

La conclusión principal de este proyecto es que las redes neuronales convolucionales son muy potentes tanto para labores de clasificación como para labores de segmentación; en este caso, ha superado a nuestro algoritmo estándar de segmentación. Sin embargo, se ha creado un precedente y los resultados son lo suficientemente prometedores como para considerar seguir trabajando sobre los mismos.

Entre las principales propuestas a futuro se destaca la comparación de los resultados con la segmentación de exudados blandos, neovascularizaciones,... y la mejora en la implementación de la red neuronal, comparando con los resultados de otras, para que sea lo suficientemente robusta como para clasificar futuras imágenes segmentadas.

Agradecimientos

Por último, agradecer a Ángel Torrado-Carvajal, profesor de la asignatura Análisis de Imagen Médica, la ayuda prestada en la elaboración de los algoritmos de segmentación de las llamadas lesiones rojas (exudados, neovascularizaciones,...)

Referencias

- [1] Joanne W.Y. Yau et al. for the Meta-Analysis for Eye Disease (META-EYE) Study Group; Global Prevalence and Major Risk Factors of Diabetic Retinopathy. *Diabetes Care* 1 March 2012; 35 (3): 556–564
- [2] Williams, R., Van Gaal, L. & Lucioni, C. Assessing the impact of complications on the costs of Type II diabetes. *Diabetologia* 45 (Suppl 1), S13–S17 (2002)Roberto
- [3] Romero-Oraá et al, Effective Fundus Image Decomposition for the Detection of Red Lesions and Hard Exudates to Aid in the Diagnosis of Diabetic Retinopathy. *Sensors (Basel)*. 2020 Nov 16;20(22):6549.
- [4] Kauppi, T., Kalesnykiene, V., Kamarainen, J.-K., Lensu, L., Sorri, I., Uusitalo, H., Kälviäinen, H., Pietilä, J., *DIARETDB0:Evaluation Database and Methodology for Diabetic Retinopathy Algorithms*
- [5] A. Biran, P. S. Bidari, A. Almazroa, V. Lakshminarayanan and K. Raahemifar, "Blood vessels extraction from retinal images using combined 2D Gabor wavelet transform with local entropy thresholding and alternative sequential filter," *2016 IEEE Canadian Conference on Electrical and Computer Engineering (CCECE)*, Vancouver, BC, Canada, 2016, pp. 1-5
- [6] Rasta SH, Partovi ME, Seyedarabi H, Javadzadeh A. A comparative study on preprocessing techniques in diabetic retinopathy retinal images: illumination correction and contrast enhancement. *J Med Signals Sens.* 2015 Jan-Mar;5(1):40-8.
- [7] Mitra A, Banerjee PS, Roy S, Roy S, Setua SK. The region of interest localization for glaucoma analysis from retinal fundus image using deep learning. *Comput Methods Programs Biomed.* 2018 Oct;165:25-35.